creative commons
COMMONS DEED

저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 이용허락규약(Legal Code)을 이해하기 쉽게 요약한 것입니다.

Disclaimer

dCollection

석사 학위논문

이미지-골격 데이터에 대한 퓨전 기법을 활용한 인간 행동 분류

영남대학교 대학원

전 자 공 학 과

전 자 공 학 전 공

김 나 현

지도교수 이 찬 수

2025년 2월

YEUNGNAM UNIVERSITY 1947
영남대학교

석사 학위논문

이미지-골격 데이터에 대한 퓨전 기법을 활용한 인간 행동 분류

지도교수 이 찬 수

이 논문을 석사학위 논문으로 제출함

2025년 2월

영남대학교 대학원

전 자 공 학 과 전 자 공 학 전 공

김 나 현

김 나 현의 석사 학위논문을 인준함

심사위원 김 성 호 印

심사위원 최 현 철 印

심사위원 이 찬 수 印

2025년 2월

영남대학교 대학원

감사의 글

학부 연구생 2년, 석사과정 2년. 도합 4년의 여정을 마무리하며 오늘 이 글을 씁니다. 걷기도 하고 달리기도 하고 때로는 넘어지며 지금에 이른 저는 무엇을 얻었을까요. 정확히 형용하기 어려운 그것을 이 논문으로 답하고자 합니다. 또, 감사하고자 합니다.

제가 대학에서 가장 처음으로 마주하고, 제가 학위 과정을 잘 이어 나갈 수 있도록 아낌없는 지원과 조언, 존중을 주신 이찬수 교수님께 깊은 감사를 드립니다. 그리고 바쁘신 와중에도 저의 논문과 발표를 심사해 주신 김성호 교수님과 최현철 교수님께 감사드립니다.

학부 연구생 시절, 작은 자동차 하나로 몰두했던 시간은 결코 잊을 수 없습니다. 그 겨울날의 정하영 선배와 최지현 선배, 변자은 선배를 기억하며 감사드립니다. 더불어 언젠가 만나고 헤어졌던 학부 연구생 선후배님들을 떠올리며 임하고 있을 여정이 언제나 행복하기를 바랍니다. 석사과정을 함께한 이제목 선배의 여정도 순탄하길 바랍니다.

컴퓨터 비전 및 인간 시각 연구실에서 함께한 박현수 박사님, 강혜란 박사님, 서한얼 연구원님께 감사드립니다. 특히, 연구실 생활을 가장 가까이서 도와주시고 가르쳐주신 혜란 선배와 한얼 선배에게 다시 한번 깊이 감사드립니다. 두 분의 진심 어린 조언과 칭찬을 마음에 담고 더욱 성장하겠습니다. 비록 짧은 시간이나마 도움을 주시고 연구의 새로운 시각을 경험하게 해주신 김종훈 박사님과 오인숙 박사님께도 감사드립니다.

언제나 저를 도와주고 함께 웃어준 친구들에게 감사합니다. 언제 어디서든, 어떤 형태로든 함께했던 파랑새 같은 순간들은 넘어진 저를 일으켜준 따듯한 힘이 되어주었습니다. 그 선의를 품고 따듯한 사람이 되겠습니다.

마지막으로, 크고 작은 사고를 일삼는 저를 딸로서, 누나로서, 언니로서, 조카로서, 손녀로서 아낌없이 사랑해 주신 가족에게 진정으로 감사드립니다. 저를 보살펴주시고 지지해 주신 엄마와 아빠, 사랑합니다.

저는 이제 소중한 한 장을 마무리하고 새로운 여정으로 나아가고자 합니다. 그 여정은 불확실할 테지만, 여러분들과 함께한 이 기억 덕분에 두렵지 않습니다. 다시 만나 이야기를 나눌 날을 기대하겠습니다.

2025년 2월

김 나 현

YEUNGNAM UNIVERSITY 1947 영남대학교

목 차

표 목차 ····· 2
그림 목차 ····· 3

1. 서론 ····· 5

2. 관련연구 ····· 6
1. 자세 추정 ····· 6
2. 이미지 시퀀스 데이터 분류 ····· 13
3. 그래프 합성곱 신경망 ····· 16
4. 데이터 퓨전 기법 ····· 18

3. 제안 모델 ····· 21
1. 이미지 시퀀스 모델 ····· 21
2. 시공간 골격 모델 ····· 22
3. 이미지-골격 퓨전 모델 ····· 24

4. 실험 및 결과 ····· 27
1. 실험 데이터셋 ····· 27
1.1 자율주행차 탑승자 데이터셋 ····· 27
1.2 NTU RGB+D 데이터셋 ····· 31
2. 실험 결과 ····· 33
2.1 자율주행차 탑승자 데이터셋 ····· 33
2.2 NTU RGB+D 데이터셋 ····· 37
3. 데이터 퓨전 기법의 효과 분석 ····· 39

5. 결론 ····· 41

참고문헌 ····· 42

ABSTRACT ····· 48

표 목차

<Table 1> 자율주행차 탑승자 데이터셋의 Class ····· 28
<Table 2> NTU RGB+D 데이터셋의 속성별 현황 ····· 31
<Table 3> NTU RGB+D 데이터셋의 카메라 각도 종류 ····· 32
<Table 4> fold별 골격 모델 및 퓨전 모델 평가 정확도 비교 ····· 33
<Table 5> 이미지 개수별 퓨전 모델 평가 정확도 비교 ····· 34
<Table 6> 레이트 퓨전 방식에 따른 퓨전 모델 평가 정확도 비교 ····· 34
<Table 7> NTU RGB+D 데이터셋의 퓨전 모델 평가 정확도 비교 ····· 37

그림 목차

<Figure 1> 탑다운 방법의 자세 추정 순서 ····· 6
<Figure 2> Mask R-CNN 모델 구조도 ····· 7
<Figure 3> HRNet 모델 구조도 ····· 8
<Figure 4> SimpleBaseline 모델 구조도 ····· 9
<Figure 5> 바텀업 방법의 자세 추정 순서 ····· 10
<Figure 6> OpenPose 데모 영상과 관절 키포인트 ····· 10
<Figure 7> PifPaf 중 PIF ····· 11
<Figure 8> PifPaf 중 PAF ····· 11
<Figure 9> HigherHRNet 모델 구조도 ····· 12
<Figure 10> CNN-LSTM 모델 구조도 ····· 13
<Figure 11> 3D-CNN 모델 구조도 ····· 14
<Figure 12> (위)2D 합성곱과 (아래)3D 합성곱의 연산 방식 ····· 14
<Figure 13> Multi-stream 모델 구조도 ····· 15
<Figure 14> 그래프 합성곱 신경망의 입력 데이터 형태 ····· 16
<Figure 15> 그래프 합성곱 신경망의 연산 ····· 17
<Figure 16> 얼리 퓨전 방식을 사용한 모델 구조도 ····· 19
<Figure 17> 레이트 퓨전 방식을 사용한 모델 구조도 ····· 20
<Figure 18> CNN-LSTM 레이어 구조도 ····· 21
<Figure 19> 인간 골격 데이터 형태 ····· 22
<Figure 20> ST-GCN 입력 데이터 형태 ····· 22
<Figure 21> ST-GCN 모델 레이어 구조도 ····· 23
<Figure 22> 이미지-골격 퓨전 모델 구조도 ····· 24
<Figure 23> 4가지 레이트 퓨전 기법 ····· 26
<Figure 24> 데이터셋에 포함된 3가지 조명 환경 ····· 27
<Figure 25> Class별 피험자의 실제 행동 ····· 28
<Figure 26> Class별 골격 데이터 형태 ····· 29
<Figure 27> 인간 신체를 표현하는 골격 인덱스 ····· 30
<Figure 28> NTU RGB+D 데이터셋의 샘플 이미지 ····· 31
<Figure 29> 골격 데이터 학습에 대한 Class별 정확도 비교 ····· 35
<Figure 30> 이미지-골격 데이터 학습에 대한 Class별 정확도 비교 ····· 36

<Figure 31> NTU RGB+D 데이터셋의 입력 데이터별 모델 평가 정확도 ····· 37
<Figure 32> 조명 환경별 골격 데이터 품질 비교 ····· 39
<Figure 33> IR 환경에서 촬영한 이미지 특징맵 추출 결과 ····· 39
<Figure 34> 로우레벨 특징(Low-level feature)이 담긴 특징맵 추출 결과 ····· 40

Ⅰ. 서 론

컴퓨터 비전에서 광범위하게 연구된 인간 자세 추정(Human Pose Estimation)은 인체 부위의 구성을 추정한 후 전신으로 종합하여 인간의 자세를 추정하는 것이다. 대표적으로 센서를 활용해 직접 자세 데이터를 측정하거나[5-9], 카메라로 촬영한 이미지와 동영상을 분석하는 방법이 있다.[10-14] 특히 이미지와 동영상으로부터 분석하는 방법은 2D 이미지로부터 2D 자세 데이터를 추출하는 단계에서 깊이 정보를 추가하여 3D 자세 데이터를 추출하는 단계까지 발전했으며, 2018년 이후부터 골격 데이터를 기반으로 한 연구가 활발히 진행되고 있다.[15] 그러나 카메라로 촬영한 이미지와 동영상으로부터 골격 데이터를 추출하는 과정에서 촬영한 환경의 조명 상태, 카메라의 각도에 따라 추출된 골격 데이터의 품질이 달라진다는 문제가 존재한다.[1]

본 연구는 이미지 시퀀스 데이터를 통해 시각적인 정보를 제공하고, 골격 데이터를 통해 인간의 자세 및 행동을 수치화한 데이터를 제공함으로써, 두 가지 데이터를 통합하여 풍부한 정보를 얻어 조명 상태에 의한 자세 추정 민감성을 극복하고자 한다. 이미지와 골격 데이터를 결합하여 효과적으로 모델을 학습하는 방법을 제시하고, 이를 통해 기존의 접근 방식보다 더욱 정확하고 유연한 인간 자세 추정 시스템을 구축하고자 한다.

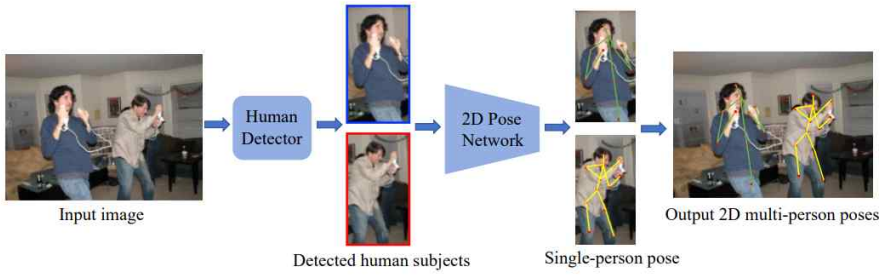
본 논문의 구성은 다음과 같다. 2장에서는 제안 모델과 관련된 연구를 살펴본다. 자세 추정 방법의 다양한 기법, 이미지 시퀀스 데이터 특징을 추출하고 분류하는 다양한 신경망, 골격 데이터 특징 추출을 위한 그래프 합성곱 신경망과 데이터 특징을 합성하는 퓨전 기법을 소개한다. 3장에서는 제안하는 모델과 구성 요소인 CNN-LSTM 모델, ST-GCN 모델에 대해 소개한다. 4장에서는 제안 모델을 자율주행차 탑승자 데이터셋과 NTU RGB+D 데이터셋에 적용한 성능 평가와 이미지, 골격 두 데이터로부터 추출된 특징을 분석한다. 5장에서는 결론을 맺는다.

Ⅱ. 관련 연구

1. 자세 추정

자세 추정은 센서를 사용하여 자세를 직접 캡처하는 방식과 카메라를 사용하여 자세를 촬영한 이미지와 비디오를 통해 자세를 추정하는 방식이 있다. 본 연구에서는 이미지 및 비디오로부터 골격을 추정하는 방식을 사용하였다.

골격 자세 추정에서, 탑다운(Top-Down) 방법과 바텀업(Bottom-Up) 방법은 사람의 관절 위치를 추정하는 두 가지 대표적인 접근 방식이다. 각각의 방법은 장단점과 적용 가능성이 다르며, 상황에 따라 적합한 방식을 선택하게 된다.



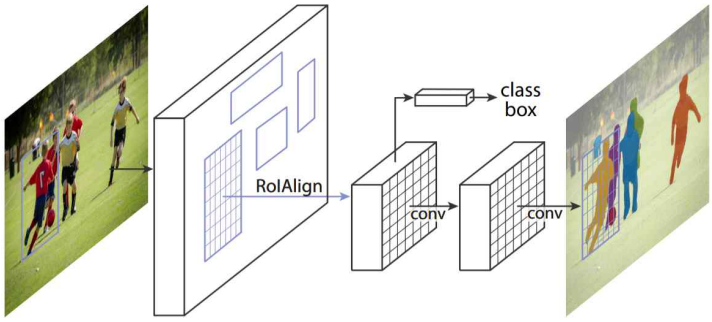
<Figure 1> 탑다운 방법의 자세 추정 순서

탑다운 방법은 먼저 이미지나 영상에서 사람의 개별적인 전체 위치를 탐지한 후, 각 사람의 관절을 추정하는 방식이다. 사람 탐지 단계에서 객체 탐지 알고리즘(예: Faster R-CNN[16], YOLO[17], SSD[18] 등)을 사용해 이미지에서 사람의 위치를 탐지하고 바운딩 박스를 결정한다. 이후 관절 추정 단계에서 결정한 각 바운딩 박스 안에서 자세 추정 모델(예: HRNet, SimpleBaseline 등)을 활용해 해당 사람의 관절 위치를 예측한다.

탑다운 방법의 장점은 각 사람의 영역을 개별적으로 처리하기 때문에 다중 인물 상황에서 복잡도가 낮다. 높은 해상도와 정확도로 개별 자세를 추정할 수

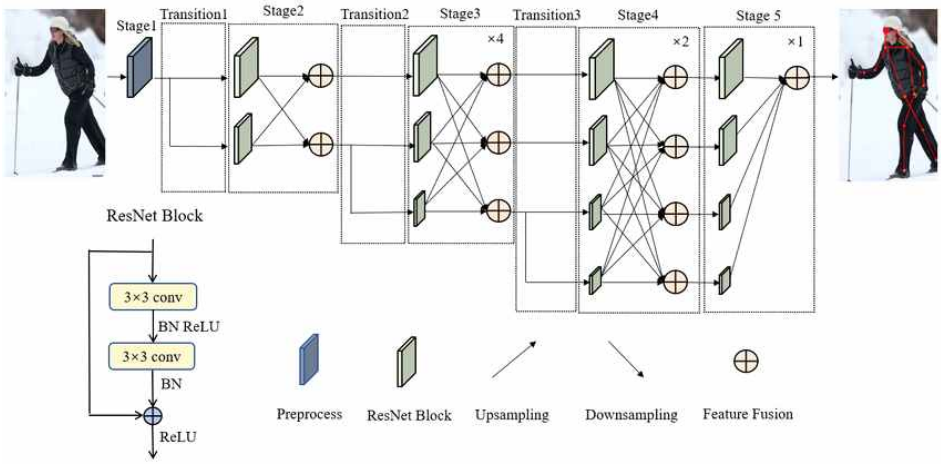
있다. 그러나 사람이 많아질수록 계산 비용이 기하급수적으로 증가한다. 객체 탐지를 먼저 수행하므로 탐지 단계에서 오류가 발생하면 자세 추정 정확도도 떨어질 수 있다.

대표적인 알고리즘으로 Mask R-CNN, HRNet, SimpleBaseline가 있다.



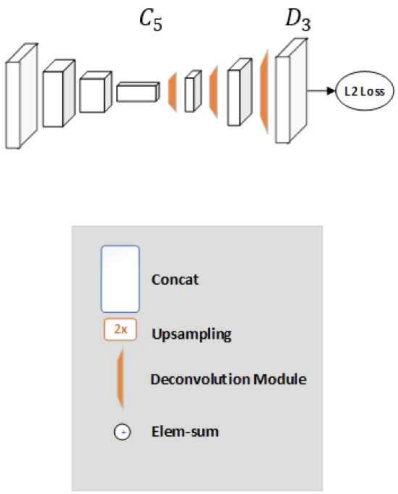
<Figure 2> Mask R-CNN 모델 구조도[19]

Mask R-CNN[19]은 객체 인스턴스 분할 작업을 위해 설계된 고급 딥러닝 아키텍처다. 이 모델은 Faster R-CNN을 기반으로 하며, RoI(Region of Interest)에서 분류와 경계 상자 회귀를 처리하는 기존 분기와 병렬로 분할 마스크를 예측하는 분기를 추가한다. 이를 통해 다양한 형태와 크기의 객체를 감지하고 각 객체를 세분화하는 유연성을 제공한다. 주요 특징으로는 RoI Pooling보다 공간 정보를 더 잘 보존하는 RoI Align, 객체 감지와 픽셀 단위 마스크 생성을 동시에 수행하는 인스턴스 세분화, 그리고 ResNet 및 ResNeXt와 같은 다양한 백본 네트워크와의 쉬운 통합이 있다. Mask R-CNN은 자율주행, 의료 영상, 증강 현실 등 다양한 분야에서 객체 감지와 세분화 작업의 정밀도로 널리 활용된다.



<Figure 3> HRNet 모델 구조도[20]

HRNet(High-Resolution Network)[20]는 인간 포즈 추정과 의미론적 세분화와 같은 작업에서 높은 품질의 특징 표현을 제공하는 최첨단 아키텍처다. 이 모델은 전통적인 아키텍처와 달리 네트워크 전반에 걸쳐 고해상도 표현을 유지하며, 고해상도와 저해상도 스트림 간의 정보를 지속적으로 융합한다. 주요 특징으로는 병렬 다중 해상도 서브네트워크를 통해 세부적인 공간 정보를 유지하는 다중 스케일 표현, 해상도 간 정보 교환을 통해 더욱 풍부한 특징 표현을 제공하는 특징 융합, 그리고 공간 해상도 보존을 통해 밀집 예측 작업에서 탁월한 성능을 발휘하는 견고성이 있다. HRNet은 정확한 위치 지정과 세부적인 공간 정보가 필요한 포즈 추정 및 의료 영상 분석과 같은 분야에서 효과적으로 사용된다.



<Figure 4> SimpleBaseline 모델 구조도[21]

SimpleBaseline[21]은 인간 포즈 추정을 위한 가볍고도 효과적인 아키텍처로, 복잡한 설계에 대한 간단한 대안으로 경쟁력 있는 결과를 제공한다. 이 아키텍처는 특징 추출을 위한 백본 네트워크와 키포인트에 해당하는 히트맵을 생성하는 여러 디컨볼루션 계층으로 구성된다. 주요 특징으로는 과도한 복잡함 없이 필수 구성 요소에 중점을 둔 최소주의 설계를 강조하는 단순성, ResNet과 같은 표준 백본 네트워크와의 호환성을 보장하는 백본 유연성, 그리고 더 복잡한 모델에 비해 낮은 계산 복잡도를 유지하는 효율성이 있다. SimpleBaseline은 단순함에도 불구하고 인간 포즈 추정 작업에서 견고한 성능을 발휘하며, 효율성이 중요한 시나리오에서 널리 사용된다.

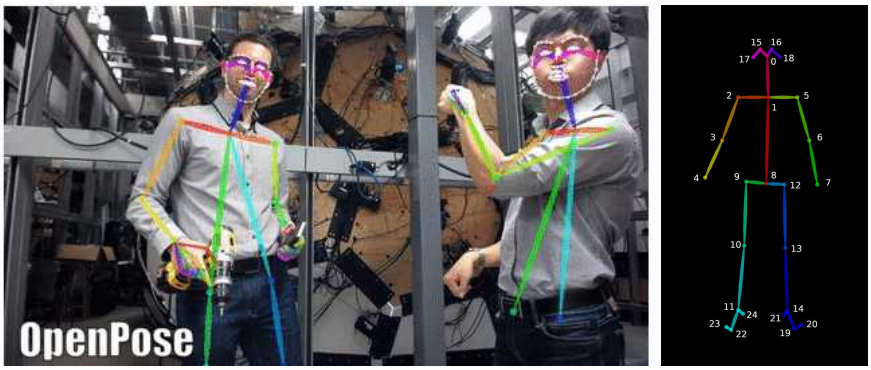


<Figure 5> 바텀업 방법의 자세 추정 순서

바텀업 방법은 먼저 이미지 전체에서 모든 관절을 탐지한 뒤, 이를 기반으로 각 사람의 자세를 구성하는 방식이다. 관절 탐지 단계에서 이미지 내 모든 관절 후보를 탐지한다. 각 관절의 위치와 유형(예: 왼쪽 팔꿈치, 오른쪽 무릎 등)을 파악한다. 이후 관절 연결 단계에서 탐지된 관절들을 그룹화하여 각 사람의 골격 구조를 생성한다.

바텀업 방법의 장점은 한 번의 처리를 통해 다수의 인물에 대해 자세 추정이 가능하므로 계산 효율성이 높다. 사람이 많아도 탐지와 연결 단계를 분리하기 때문에 처리 시간이 크게 증가하지 않는다. 그러나 여러 사람이 밀집된 이미지에서 추정된 관절들을 잘못 연결할 가능성이 있다. 개별 관절 추정의 해상도나 정밀도가 탑다운 방식보다 낮을 수 있다.

대표적인 알고리즘으로 OpenPose, PifPaf, HigherHRNet이 있다.



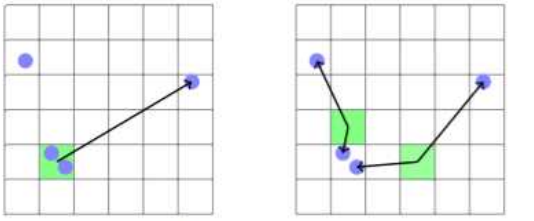
<Figure 6> OpenPose 데모 영상과 관절 키포인트

OpenPose[22]는 인간 포즈 추정을 위한 초기 공개형 딥러닝 프레임워크로, 다중 인물 포즈 추정을 동시에 수행할 수 있는 능력을 갖추고 있다. 이 모델은 2

단계 접근 방식을 사용하며, 먼저 이미지에서 신체 부위의 히트맵을 생성한 후, 이러한 히트맵을 연결하여 사람의 포즈를 완성한다. OpenPose의 주요 특징으로는 다중 인물의 포즈를 실시간으로 추정할 수 있는 효율성, 다양한 신체 부위와 관절을 정확히 감지하는 정밀성, 그리고 광범위한 응용 가능성을 꼽을 수 있다. OpenPose는 특히 스포츠 분석, 게임 인터페이스, 의료 재활 등 다양한 분야에서 널리 활용된다.

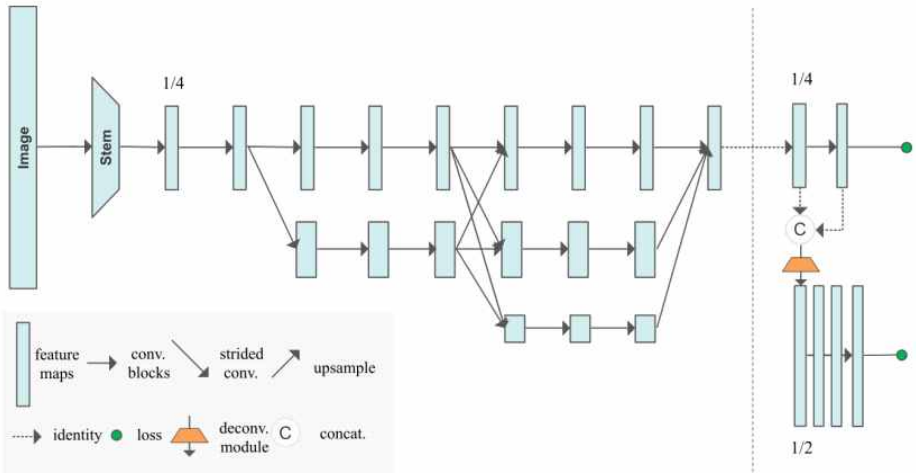


<Figure 7> PifPaf 중 PIF



<Figure 8> PifPaf 중 PAF

PifPaf[23]는 포즈 추정 분야에서 높은 정확도를 제공하는 최첨단 딥러닝 모델로, OpenPose의 단점을 보완하며 개발되었다. PifPaf는 신체 부위와 관절 간 연결을 추정하기 위해 PIF(Part Intensity Fields)와 PAF(Part Association Fields)를 활용한다. 이를 통해 복잡한 배경이나 밀집된 사람들 사이에서도 신뢰성 높은 결과를 제공한다. 주요 특징으로는 픽셀 단위의 세밀한 감지, 복잡한 환경에서도 높은 정확도, 그리고 확장 가능성을 들 수 있다. PifPaf는 특히 군중 분석, 비디오 감시, 스포츠 이벤트 추적 등에서 강력한 성능을 발휘한다.

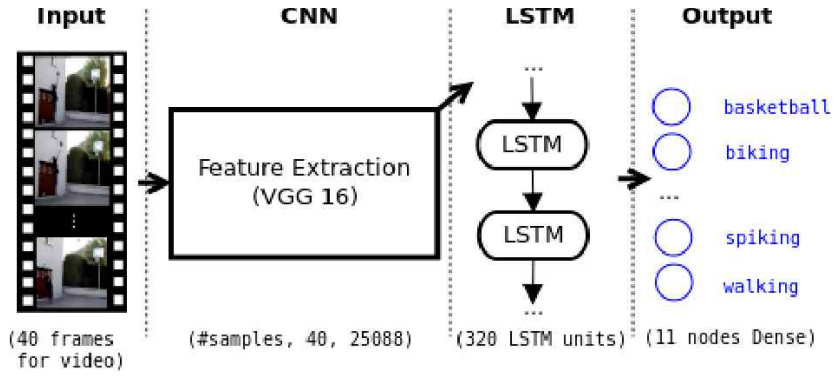


<Figure 9> HigherHRNet 모델 구조도[24]

HigherHRNet[24]은 HRNet의 확장 버전으로, 인간 포즈 추정에서 높은 해상도와 정밀도를 제공한다. 이 모델은 고해상도 표현을 유지하며, 다중 스케일의 히트맵을 통합하여 복잡한 포즈를 정확하게 추정한다. HigherHRNet의 주요 특징으로는 해상도와 정확도의 균형 유지, 다중 인물 상황에서 뛰어난 성능, 그리고 다양한 크기의 객체와 관절을 효과적으로 처리할 수 있는 유연성을 들 수 있다. 이 모델은 인간 포즈 추정에서 새로운 기준을 제시하며, 스포츠 과학, 컴퓨터 그래픽스, 의료 영상 분석 등에서 널리 활용된다.

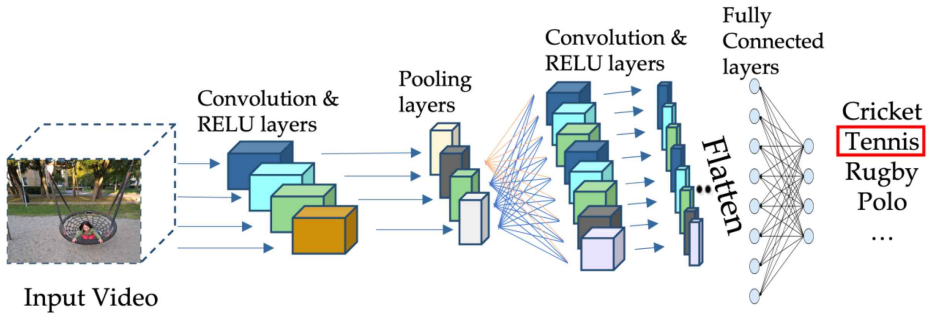
2. 이미지 시퀀스 분류

동적인 인간의 행동을 표현하는 다양한 데이터 중에 비디오가 있다. 비디오는 이미지가 시퀀스형태로 존재한다. 따라서 이미지 시퀀스 데이터의 시간적, 공간적 특성을 모두 고려할 필요가 있으므로 이를 위한 고안된 접근 방식들을 살펴보았다.[25-29]

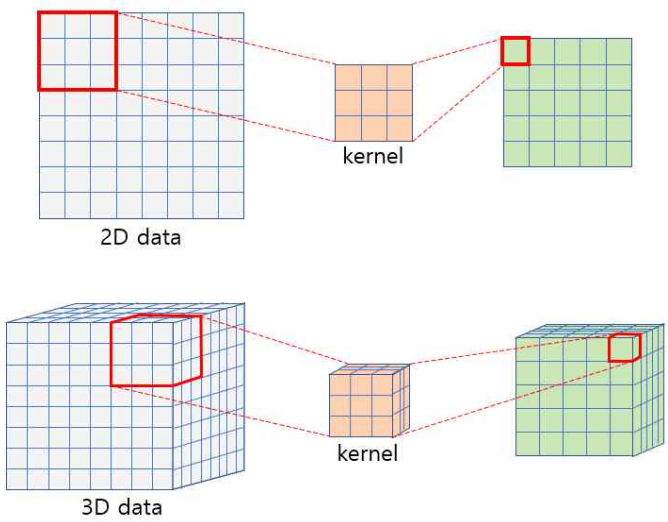


<Figure 10> CNN-LSTM 모델 구조도[30]

CNN-LSTM[30] 모델은 합성곱 신경망(Convolutional Neural Network, CNN)[44]과 LSTM(Long Short-Term Memory)[61]을 결합하여 이미지 시퀀스 데이터의 시공간적 특성을 고려할 수 있다. 합성곱 신경망은 각 프레임 이미지의 공간적 특징을 추출하고, LSTM은 이러한 특징들의 시간적 관계를 학습한다. 임의의 길이를 가진 이미지 시퀀스 데이터를 처리할 수 있으며, 시간에 따른 특징의 변화를 효과적으로 포착할 수 있다는 장점이 있다.

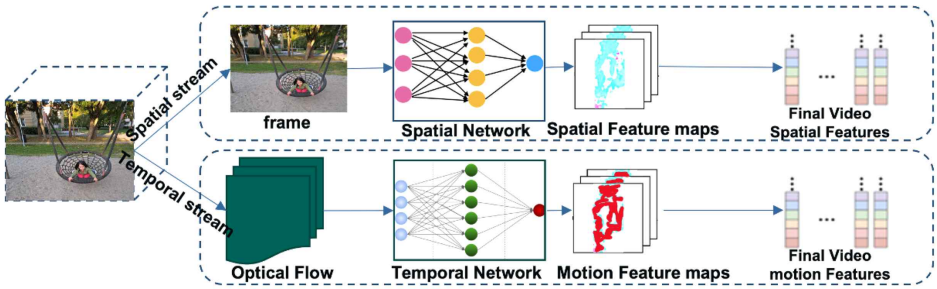


<Figure 11> 3D-CNN 모델 구조도[33]



<Figure 12> (위)2D 합성곱과 (아래)3D 합성곱의 연산 방식

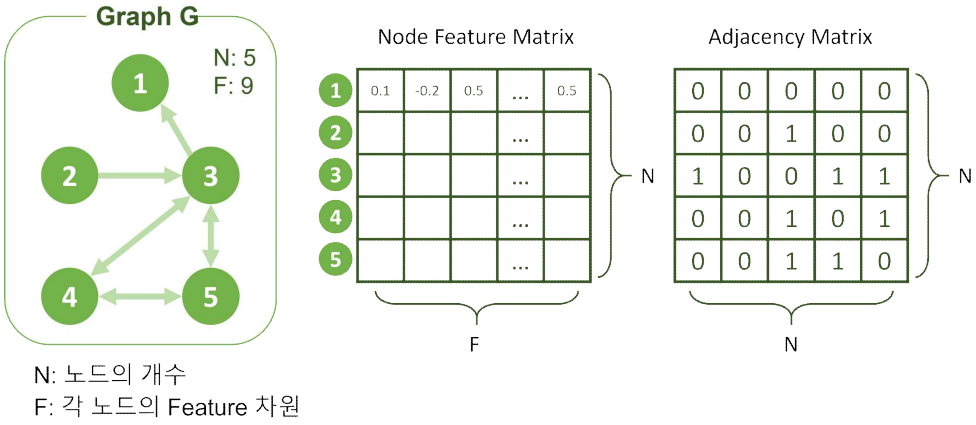
3D-CNN은 2D 합성곱 연산의 개념을 확장하여 비디오의 시공간적 특성을 동시에 처리할 수 있다. 3D 합성곱 연산을 사용하여 입력 비디오의 시간과 공간 차원을 모두 고려한다. 이는 움직임 정보를 직접적으로 학습할 수 있어 동작 인식 등의 작업에 효과적이지만 계산 비용이 높아 처리 속도가 느릴 수 있다.



<Figure 13> Multi-stream 모델 구조도[25]

Multi-stream 접근 방식은 비디오의 다양한 측면을 별도의 스트림으로 처리한 후 결합한다. 일반적으로 RGB 이미지를 처리하는 스트림과 광학 흐름(Optical Flow) 이미지를 처리하는 스트림으로 구성된다. 광학 흐름 이미지는 연속된 이미지 사이의 움직임을 시각적으로 표현한 것이다. 이 이미지는 일반적으로 HSV 색상 공간을 사용하여 각 픽셀의 이동 방향과 거리를 벡터로 나타낸다. 색조(Hue)는 움직임의 방향을 나타내고, 채도(Saturation)는 움직임의 크기를 나타낸다. 물체 자체 움직임 또는 카메라의 움직임으로 인한 이미지 객체의 겉보기 움직임 패턴을 보여줄 수 있다. 높은 프레임률의 이미지에서 더 정확한 광학 흐름을 얻을 수 있으며 연속된 프레임 간의 변위가 작을수록 추정이 더 정확하다. RGB 이미지 스트림과 광학 흐름 이미지 스트림으로부터 추출된 특징들을 후반부에서 융합하여 최종 분류를 수행한다. 이는 움직임 정보와 외관 정보를 명시적으로 분리하여 처리함으로써 더 풍부한 특징을 추출할 수 있다.[39-41]

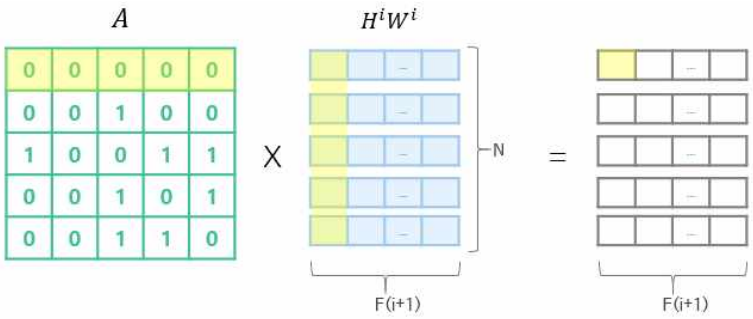
3. 그래프 합성곱 신경망



<Figure 14> 그래프 합성곱 신경망의 입력 데이터 형태

그래프 합성곱 신경망(Graph Convolutional Network, GCN)[42]은 그래프 형태의 데이터를 효과적으로 학습할 수 있도록 설계된 신경망으로, 그래프 신경망(GNN)[43]의 알고리즘에 합성곱 신경망(CNN)의 합성곱 연산 개념을 접목한 모델이다. 그래프 데이터는 노드(Node)와 이를 연결하는 엣지(Edge)로 구성되며, 노드는 특징(Feature) 정보를, 엣지는 노드 간의 관계 정보를 나타낸다.

GCN은 이러한 그래프 데이터의 정보를 학습하기 위해 노드 특징 행렬(Node Feature Matrix)과 인접 행렬(Adjacency Matrix)을 활용한다. 노드 특징 행렬은 각 노드의 특성을, 인접 행렬은 노드 간 연결 관계를 나타낸다. 이를 기반으로, 그래프의 모든 정보를 반영한 새로운 표현을 생성한다.



<Figure 15> 그래프 합성곱 신경망의 연산

특히, 인접 행렬을 노드 특징 행렬에 곱하는 과정을 통해 각 노드와 연결된 주변 노드의 정보를 집계하여 특징을 업데이트한다. 이때 생성된 행렬의 값은 노드와 연결된 모든 주변 노드의 특징 값을 같은 인덱스의 차원끼리 합산한 결과이다. 이러한 연산을 반복함으로써, 각 노드는 자신의 주변 이웃으로부터 정보를 통합해 더 풍부한 표현을 학습할 수 있게 된다.

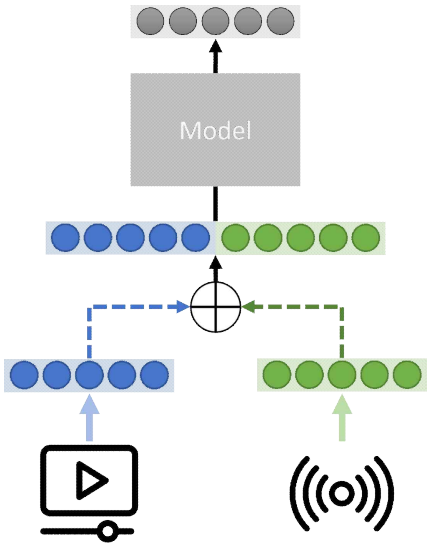
4. 데이터 퓨전 기법

데이터 퓨전이란 서로 다른 형태의 데이터를 상호 융합하는 과정을 말한다. 개별 데이터로부터 추출된 정보보다 정확하고 유용한 정보를 얻기 위하여 여러 형태의 데이터를 통합할 수 있다. 이는 데이터셋의 크기와 품질을 개선하여 모델 학습의 성능향상에 도움을 줄 수 있다.[45-50]

모델 학습 중에 데이터 퓨전 과정을 포함한 모델을 데이터 퓨전 모델이라 한다. 데이터 퓨전 과정은 모델에 입력되기 전에 원시 데이터를 융합하여 학습할 수 있고[51-55], 각각의 데이터로부터 적절한 네트워크를 사용하여 충분히 특징 정보를 추출한 후에 결과를 융합하여 학습할 수 있다.[56-60] 또한, 같은 네트워크를 사용하되 각 데이터를 동시에 학습시키지 않고 특정 모델의 깊이에서 특징맵(Feature Map)을 퓨전하여 유연성을 가지고 학습시킬 수 있다.

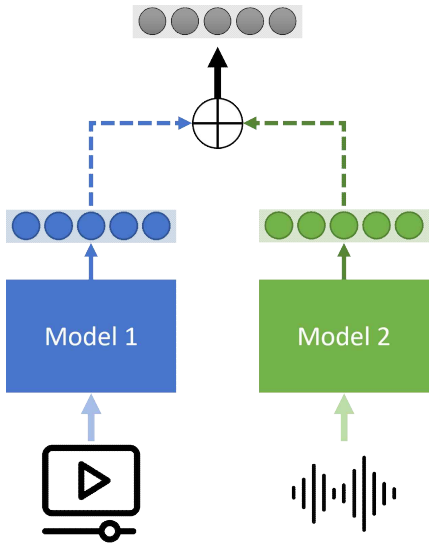
이러한 퓨전 모델의 설계는 이전 연구들에서도 다양한 방식으로 시도되었다. 예를 들어, 라이다 센서 데이터와 카메라 RGB 이미지를 퓨전할 수 있다. 이때 라이다 센서 데이터를 RGB 이미지에 투영하여 물체 인식을 시도할 수 있고, 각각의 데이터로부터 독립적인 물체 인식을 시도한 후 그 결과를 융합하여 최종 인식을 결정할 수 있다.[46, 50]

다수의 데이터를 처리하거나 다양한 정보 소스를 결합할 때, 데이터를 통합하는 방식으로 얼리 퓨전(Early Fusion)과 레이트 퓨전(Late Fusion)이 자주 사용된다. 두 방식은 데이터를 결합하는 시점과 방법에서 차이가 있다.



<Figure 16> 얼리 퓨전 방식을 사용한 모델 구조도

얼리 퓨전은 데이터를 처리하기 전에 각 데이터의 정보를 하나의 통합된 입력으로 결합하여 모델에 전달하는 방식이다. 통합된 데이터를 입력으로 사용하여 모델이 이를 동시에 학습한다. 데이터를 조기에 결합하므로 학습할 데이터들의 정보 간의 상관관계를 모델이 학습하여, 정교한 특징을 추출할 수 있다. 이를 통해 비디오와 오디오 데이터를 시간 축에서 결합하거나, 텍스트와 이미지 데이터를 병합해 입력하는 멀티모달 자연어 처리를 수행할 수 있다. 그러나 고차원 데이터의 결합으로 인해 계산 비용이 증가할 수 있고, 하나의 데이터가 손실되거나 품질이 저하되면 전체 모델 성능에 부정적인 영향을 미칠 수 있다.



<Figure 17> 레이트 퓨전 방식을 사용한 모델 구조도

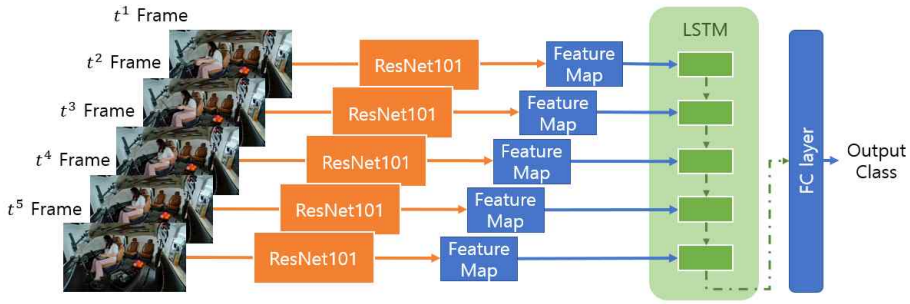
레이트 퓨전은 각 학습 데이터를 개별적으로 처리한 후, 결과를 결합하여 최종적인 결정을 내리는 방식이다. 보통 학습 데이터마다 별도의 모델을 사용하며, 마지막에 결과(예: 확률, 임베딩 등)를 통합한다. 학습 데이터마다 독립적인 처리가 가능하여 그에 최적화된 모델을 설계할 수 있다. 학습 데이터가 손실되거나 품질이 저하되어도 전체 모델 성능에 미치는 영향이 적다. 이를 이용하여 비디오 분석에서 프레임 이미지는 합성곱 신경망, 오디오는 순환 신경망(RNN)으로 처리한 후 결과를 결합하거나, 텍스트 데이터는 Transformer로, 이미지 데이터는 합성곱 신경망으로 처리한 후 결과 결합할 수 있다.

얼리 퓨전에 비하여 모달리티 간의 상관관계를 학습하기 어렵다는 우려가 있으며, 결합 과정에서 모달리티 간 중요한 상호작용 정보가 손실될 가능성이 있다.

Ⅲ. 제안 모델

이 장에서는 이미지 데이터와 골격 데이터를 동시에 학습할 수 있는 모델 구조를 설명하고자 한다. 제안한 모델은 시계열 이미지 데이터와 골격 데이터를 학습하기 위한 두 가지 레이어 구조로 구성되었다. 시계열 이미지 데이터의 핵심 정보를 추출하기 위하여 CNN-LSTM[30] 레이어 구조를 사용하고, 골격 데이터의 핵심 정보를 추출하기 위하여 ST-GCN[62] 레이어 구조를 사용하였다.

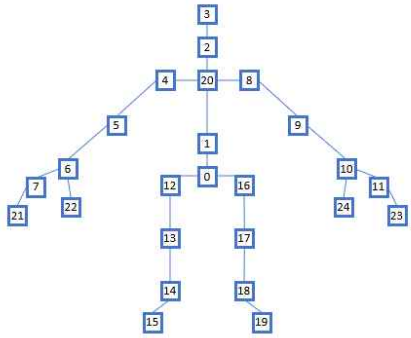
1. 이미지 시퀀스 모델



<Figure 18> CNN-LSTM 레이어 구조도

CNN-LSTM 모델은 CNN(Convolutional Neural Network)와 LSTM(Long Short-Term Memory)를 결합하여 이미지 시퀀스 데이터의 시공간적 특성을 효과적으로 학습할 수 있는 구조를 갖추고 있다. CNN은 각 프레임 이미지의 공간적 특징을 추출하며, 특히 ResNet101 레이어를 활용해 고품질의 특징맵을 생성한다. 이렇게 추출된 공간적 특징은 시계열 데이터 학습에 강점을 가진 LSTM 레이어에 순서대로 입력되어, 프레임 간의 시간적 관계를 학습한다. 이를 통해 CNN이 단독으로 처리할 경우 시계열 데이터의 시간적 특성을 고려하지 못하는 한계를 보완하고, 시간에 따른 특징 변화를 포착하여 임의의 길이를 가진 이미지 시퀀스 데이터를 효과적으로 처리할 수 있다.

2. 시공간 골격 모델



<Figure 19> 인간 골격 데이터 형태

Adjacency Matrix

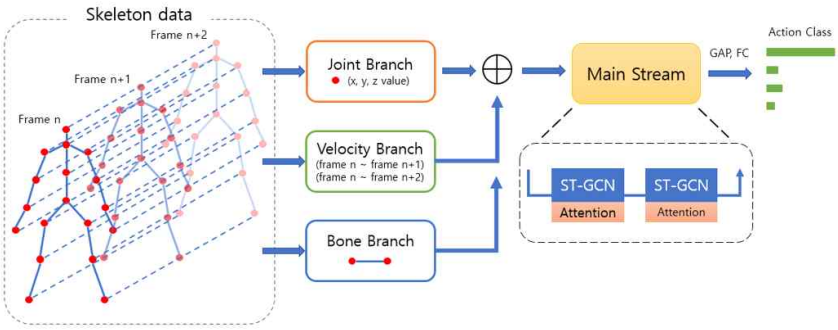
	0	1	2	3	4	...	19	20	21	22	23	24
0	1	1	0	0	0	...	0	0	0	0	1	1
1	1	1	0	0	0	...	0	0	0	0	1	1
2	0	0	1	1	0	...	0	0	0	0	0	0
3	0	0	1	1	0	...	0	0	0	0	0	0
4	0	0	0	0	1	...	0	0	0	0	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...
19	0	0	0	0	0	...	1	0	0	0	0	0
20	0	0	0	0	0	...	0	1	0	0	0	0
21	0	0	0	0	0	...	0	0	1	0	0	0
22	0	0	0	0	0	...	0	0	0	1	0	0
23	1	1	0	0	0	...	0	0	0	0	1	1
24	1	1	0	0	0	...	0	0	0	0	1	1

Node Feature Matrix

0	x_0	y_0	z_0	xf_0^1	yf_0^1	zf_0^1	xf_0^2	yf_0^2	zf_0^2
1	x_1	y_1	z_1	xf_1^1	yf_1^1	zf_1^1	xf_1^2	yf_1^2	zf_1^2
2	x_2	y_2	z_2	xf_2^1	yf_2^1	zf_2^1	xf_2^2	yf_2^2	zf_2^2
3	x_3	y_3	z_3	xf_3^1	yf_3^1	zf_3^1	xf_3^2	yf_3^2	zf_3^2
4	x_4	y_4	z_4	xf_4^1	yf_4^1	zf_4^1	xf_4^1	yf_4^1	zf_4^1
...	...	...	...	...	...	...	...	...	...
19	x_{19}	y_{19}	z_{19}	xf_{19}^1	yf_{19}^1	zf_{19}^1	xf_{19}^2	yf_{19}^2	zf_{19}^2
20	x_{20}	y_{20}	z_{20}	xf_{20}^1	yf_{20}^1	zf_{20}^1	xf_{20}^2	yf_{20}^2	zf_{20}^2
21	x_{21}	y_{21}	z_{21}	xf_{21}^1	yf_{21}^1	zf_{21}^1	xf_{21}^2	yf_{21}^2	zf_{21}^2
22	x_{22}	y_{22}	z_{22}	xf_{22}^1	yf_{22}^1	zf_{22}^1	xf_{22}^2	yf_{22}^2	zf_{22}^2
23	x_{23}	y_{23}	z_{23}	xf_{23}^1	yf_{23}^1	zf_{23}^1	xf_{23}^2	yf_{23}^2	zf_{23}^2
24	x_{24}	y_{24}	z_{24}	xf_{24}^1	yf_{24}^1	zf_{24}^1	xf_{24}^2	yf_{24}^2	zf_{24}^2

<Figure 20> ST-GCN 입력 데이터 형태

ST-GCN(Spatial Temporal Graph Convolutional Networks)은 그래프 구조 데이터의 시간적, 공간적 요소를 모두 고려하는 신경망이다. 이를 통해 인간의 행동을 학습할 수 있다. Figure 19와 같이 인간 행동을 표현한 골격 데이터를 그래프 형식으로 정의하고 합성곱 방식으로 특징을 추출한다. 이때 하나의 프레임 내의 관절을 하나의 노드로 간주하고 인체 구조에 따라 엣지로 연결하여 인체 구조에 따른 관절 간의 관계를 공간적 특징으로 간주하고 학습한다. 또한, 각 관절은 연속 프레임에서 같은 관절과 연결하여 움직이는 동안의 해당 관절의 궤적을 시간적 특징으로 간주하고 학습한다.



<Figure 21> ST-GCN 모델 레이어 구조도

입력 데이터를 증가시키고 모델 성능을 향상시키기 위해 관절, 운동 속도, 뼈 데이터를 동일한 모델 구조를 가진 3가지 Branch에 개별적으로 공급한다. 입력 받은 3차원 골격 데이터를 3가지 Branch에 입력하기 위한 전처리를 진행한다.

$$j_i = x_i - x_1 \quad (1)$$

$$v_{tslow} = x_{t+1} - x_t \quad (2)$$

$$v_{tfast} = x_{t+2} - x_t \quad (3)$$

$$b_i = x_i - x_{adj} \quad (4)$$

$$a_i = \arccos\left(\frac{b_i}{\| b_i \|}\right) \quad (5)$$

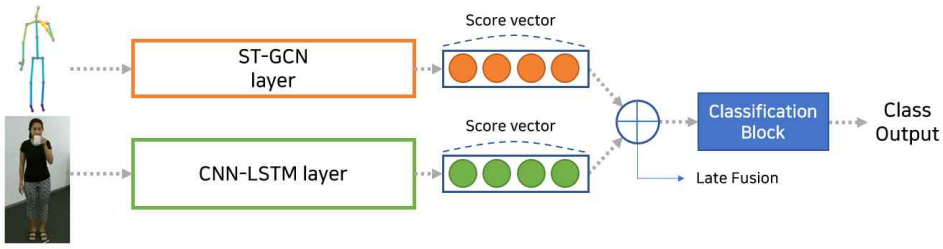
프레임별 관절 위치 특징은 모든 25개 3차원 관절과 기준 관절(1-척추 중앙)을 기점으로 계산한 상대 좌표(식 1)로 구성된다. 관절 속도 특징은 프레임 간의 관절 위치 변화량을 계산한다. 이때 각 관절에 따라 빠른 행동 속도와 느린

행동 속도를 계산한다. 빠른 행동 속도는 2프레임마다 관절의 변화량을 계산(식 2)하고, 느린 행동 속도는 1프레임마다 관절의 변화량을 계산(식 3)하여 특징 벡터로 나타낸다. 뼈 특징은 관절의 인접한 관절(x_{adj}) 사이의 연결을 고려하여 계산한 벡터(식 4)와 벡터의 각도(식 5)를 사용하였다.

이때 각 Branch의 레이어는 ST-GCN Block과 Attention Block으로 구성되어 있다. ST-GCN Block에서 3차원 골격 데이터의 시간적 공간적 특징을 추출한 다음, 추출한 특징에 주목 기법을 적용하였다. 최종적으로 하나로 융합된 각 Branch의 출력은 Main Stream에 입력된다.

최종적으로 세 Branch의 융합 결과를 최종 결정으로 선택한 후, Main Stream으로 전달한다. Main Stream의 출력인 특징맵은 평탄화 후 FC(Fully Connected) 레이어에서 최종 클래스를 결정한다.

3. 이미지-골격 퓨전 모델



<Figure 22> 이미지-골격 퓨전 모델 구조도

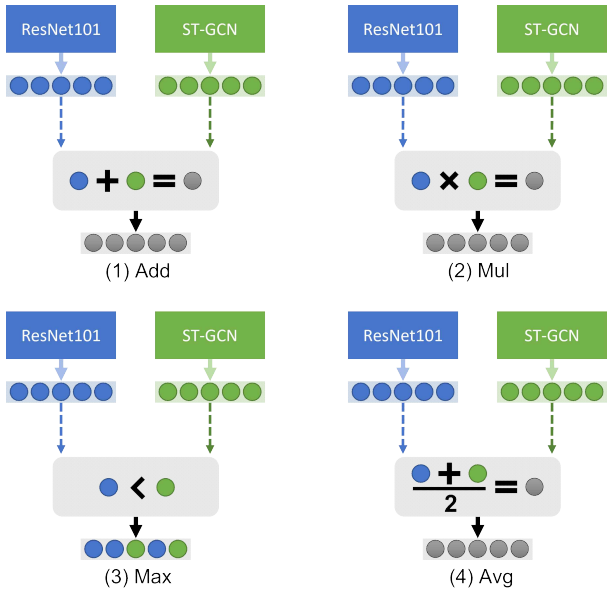
이미지 시퀀스 데이터와 골격 데이터로부터 각각 생성된 특징맵을 활용하여 각 데이터의 중요한 특성을 추출한 후, 이를 평탄화하여 하나의 통합 벡터로 퓨전했다. 이 퓨전 과정은 이미지가 제공하는 시각적 정보와 골격 데이터가 담고 있는 구조적 및 운동학적 정보를 모두 반영할 수 있는 강력한 특징 표현을 가능하게 한다. 퓨전된 벡터는 두 데이터의 상호 보완적인 특성을 효과적으로 통합하여, 이미지의 세부적인 시각적 단서와 골격 기반의 움직임 패턴을 동시에 분석할 수 있게 한다. 이를 통해 최종적으로 조명 조건에 의한 저품질 골격 데이터를 극복하고, 정밀하게 분류할 수 있는 기초 데이터를 제공한다.

첫 번째 입력 데이터인 이미지 시퀀스 데이터는 3단원 1절에 소개한 CNN-LSTM 모델을 사용하여 분석하였다. 이 모델은 사람의 행동과 진행 방향을 분류하는 데 있어 공간적 특징과 시간적 특징을 동시에 고려하는 강력한 구조를 가진다. 입력 데이터는 연속적인 프레임 이미지로 구성되며, 행동과 방향을 나타내는 시간적 연속성을 포함하고 있다. 각 프레임은 ResNet101과 같은 사전 학습된 CNN을 통해 처리되어 중요한 공간적 특징이 추출된다. CNN을 통해 얻어진 특징 맵은 LSTM에 입력되어 시간 축을 따라 변화하는 데이터 패턴을 학습한다. LSTM은 시간적 관계를 효과적으로 포착하여 행동의 변화나 방향성을 반영하는 중요한 특징을 학습한다. 이후, LSTM의 출력은 FC 레이어를 통해 퓨전을 위한 Score 벡터를 도출한다. 이 구조는 공간적 특징과 시간적 특징을 결합함으로써 사람의 행동을 정밀하게 인식하고 분석할 수 있는 장점을 가진다.

3단원 1절에 소개한 CNN-LSTM 모델을 사용하여 분석한 것과 달리, 두 번째 입력 데이터인 골격 데이터를 활용한 행동 분석에서는 3단원 2절에 소개한 ST-GCN 모델을 사용하였다. 이 모델은 사람의 관절 정보를 기반으로 행동을 분류하며, 공간적, 시간적 관계를 그래프 구조로 모델링하는데 강점을 가진다.

ST-GCN의 세가지 Branch 중, Joint Branch는 관절의 (x, y, z) 위치 값을 입력으로 받아 관절 간의 관계를 학습한다. Velocity Branch는 연속된 프레임 간 관절의 위치 변화량을 기반으로 움직임의 속도를 학습하며, Bone Branch는 관절을 연결하는 뼈의 정보(길이 및 방향)를 학습한다. 이러한 세 가지 특징들은 각각의 분기에서 독립적으로 처리된 후, 통합되어 Main Stream으로 전달된다.

Main Stream에서는 ST-GCN 블록이 사용되어 Skeleton 데이터의 공간적, 시간적 특징을 그래프 형태로 분석한다. Attention 메커니즘이 포함된 ST-GCN은 중요한 관절이나 움직임에 더 집중할 수 있도록 설계되었으며, 최종적으로 Global Average Pooling(GAP)과 FC 레이어를 통해 퓨전을 위한 Score 벡터를 도출한다.



<Figure 23> 4가지 레이트 퓨전 기법

본 논문에서는 4가지 레이트 퓨전 기법을 사용하여 데이터셋을 학습한 후, 각 퓨전 기법별로 평가 정확도를 비교하는 방법을 제시한다. 여기서 사용되는 4가지 레이트 퓨전 기법은 다음과 같다.

더하기(Add)[63]: 이 기법은 각 요소들끼리 더하여 퓨전하는 방법이다. 즉, 두 개 이상의 데이터가 있을 때 동일한 인덱스에 위치한 값들을 모두 더하여 새로운 값을 생성한다.

곱하기(Mul)[63]: 이 기법은 각 요소들끼리 곱하는 방법이다. 즉, 동일한 인덱스에 위치한 값들을 모두 곱하여 새로운 값을 도출한다.

큰 수 비교(Max)[64]: 이 기법은 각 인덱스에서 가장 큰 값을 선택하는 방법이다. 각 데이터의 동일한 위치에서 가장 큰 값을 채택하여 새로운 값을 생성한다.

평균(Avg)[63]: 이 기법은 각 요소들끼리 평균을 내어 퓨전하는 방법이다. 동일한 인덱스에 있는 값들을 모두 더한 후, 그 값을 요소의 개수로 나누어 평균을 구한다.

이러한 4가지 퓨전 기법을 통해 얻은 결과를 바탕으로, 각 기법의 평가 정확도를 비교하여 가장 적합한 방법을 분석하고자 한다.

Ⅳ. 실험 및 결과

1. 실험 데이터셋

1.1 자율주행차 탑승자 데이터셋



<Figure 24> 데이터셋에 포함된 3가지 조명 환경

현대 GV80 차량을 실제 사이즈로 구현한 모형 구조물에서 20대 대학생 남녀 40명을 대상으로 영상 데이터를 수집하였다. 피험자의 행동을 촬영할 카메라는 170도 화각의 광각 RGB+IR 카메라를 사용하였고 차량 A필러 중간부에서 운전석에 앉은 피험자의 전신을 담을 수 있도록 고정하였다. 피험자는 Figure 24와 같이 RGB, RGB+IR, IR 3가지 조명 환경 속에서 운전석에 탑승한 채로 10가지 시나리오에 따른 11가지 행동을 10회 반복 수행하였다.

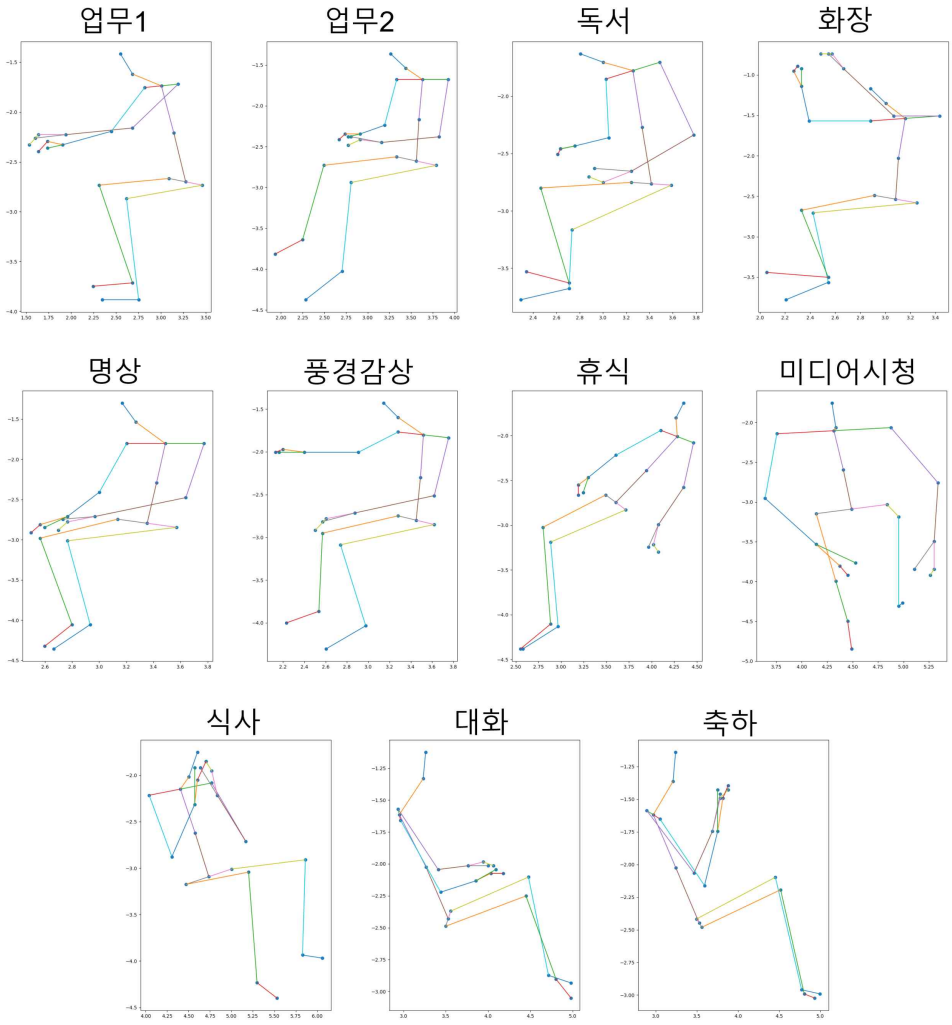
피험자가 수행한 11가지 행동의 세부적인 특징은 아래의 표에 명시하였다. 행동을 수행할 때 사용하는 손은 왼손, 오른손 또는 양손을 모두 사용할 수 있도록 하였다.

<Table 1> 자율주행차 탑승자 데이터셋의 Class

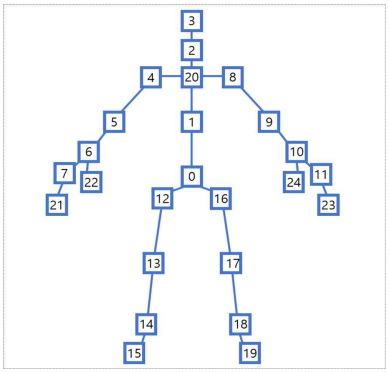
Class	행동
1-1. **업무**	한손또는 두손을노트북에 올려 둔 상태로얼굴이 노트북 화면을 향함
1-2. **업무1**	노트북을 무릎에 가져온 후 얼굴과 손이 노트북을 향함
2. **휴식**	의자에 완전히 눕기
3. **대화**	몸이 뒷좌석을 향함, 동승자와 서로 마주봄
4. **풍경 감상**	창문을 바라보고 구경하기 / 창문 조절하기
5. **식사**	손(또는 수저)이 입으로 갔다가 내려옴
6. **미디어 시청**	오른쪽에 비치된 탭을 조작하기
7. **독서**	두 손으로 책을 들고 얼굴이 책을 향함
8. **축하**	박수를 계속 치는 움직임
9. **화장**	거울에 집중한 채 손을 얼굴 부위에서 움직임
10. **명상**	편하게 기대어 앉은 후 움직임이 없는 상태



<Figure 25> Class별 피험자의 실제 행동



<Figure 26> Class별 골격 데이터 형태



0	골반(pelvis)	9	오른쪽 팔꿈치	18	오른쪽 발목
1	척추 중앙	10	오른손 손목	19	오른발
2	목	11	오른손 손등	20	어깨 중앙
3	머리	12	왼쪽 엉덩이	21	왼손 중지
4	왼쪽 어깨	13	왼쪽 무릎	22	왼손 엄지
5	왼쪽 팔꿈치	14	왼쪽 발목	23	오른손 중지
6	왼손 손목	15	왼발	24	오른손 엄지
7	왼손 손등	16	오른쪽 엉덩이		
8	오른쪽 어깨	17	오른쪽 무릎		

<Figure 27> 인간 신체를 표현하는 골격 인덱스

피험자가 수행한 행동을 촬영한 30fps 영상으로부터 학습에 사용할 행동을 150개 프레임으로 추출하였다. 추출한 각각의 프레임에서 피험자의 순간적인 자세를 골격 형태로 추출하였다. 골격 데이터는 3차원 좌표값을 가진 25개 관절로 구성하였다. 이를 통해 움직임의 공간적 특징과 시간적 변화가 동시에 표현되며 3차원 골격 데이터의 x축은 피험자의 좌우, y축은 피험자의 상하, z축은 피험자와 카메라 사이의 거리를 나타낸다.

피험자의 신장에 따라 3차원 골격 데이터의 x, y, z축 좌표값의 범위가 다르며, 이는 학습에 영향을 미칠 수 있다. 효율적이고 정확한 학습을 진행하기 위해 피험자 간의 신장 차이를 줄일 필요가 있다. 또한, 피험자가 수행한 11가지 행동은 피험자의 탑승 방향과 대화 행동 수행 시 대화 상대인 실험자와의 구분이 필요하므로 탑승 위치 정보가 보존될 필요가 있다.

$$d = \sqrt{(x_0 - x_{20})^2 + (y_0 - y_{20})^2} \quad (6)$$

$$x_{scaled\ _i} = \frac{x_i}{d} \quad (7)$$

$$y_{scaled\ _i} = \frac{y_i}{d} \quad (8)$$

따라서 Figure 27을 참고하여 피험자의 신장에 따른 차이만 줄이기 위해 x축, y축에 대하여 스케일링을 적용하였다. 각 프레임의 x축, y축에 대하여 0-골반으로부터 20-어깨 중앙까지의 거리를 기준으로 3차원 골격 데이터 좌표값의 정규화를 진행하였다. 식 6을 사용하여 2차원 공간에서 0-골반으로부터 20-어깨 중앙까지의 거리 d를 구한다. 각각의 25개 관절에 대하여 x축, y축 좌표값에 거리 d를 나누어 정규화하였다.(식 7, 식 8)

1.2 NTU RGB+D 데이터셋



<Figure 28> NTU RGB+D 데이터셋의 샘플 이미지[65, 66]

NTU RGB+D[65, 66] 데이터셋은 40개의 별개의 피사체에서 수집된 56,000개 이상의 비디오 샘플과 400만 개의 프레임을 가진 RGB+D 인간 행동 인식을 위한 대규모 데이터셋이다. 3대의 카메라를 사용하여 정면, 측면, 45° 사면에서 촬영하였으며, 수집된 행동에는 일상생활 행동, 상호작용 행동 및 운동 관련 행동을 포함한 60개의 다양한 행동 클래스가 포함되어 있다. 다양한 행동에 대하여 수집된 데이터로 일반적인 행동인식 알고리즘을 개발하기 위하여 유용하다.

<Table 2> NTU RGB+D 데이터셋의 속성별 현황

속성	수
피험자 수	60
골격 관절 수	25
전체 데이터 수	57,600
일상생활 Class 수	82
병적 행동 Class 수	12
군중 행동 Class 수	26
전체 Class 수	120

<Table 3> NTU RGB+D 데이터셋의 카메라 각도 종류[65]

Setup No.	Height (m)	Distance (m)	Setup No.	Height (m)	Distance (m)
1	1.7	3.5	2	1.7	2.5
3	1.4	2.5	4	1.2	3
5	1.2	3	6	0.8	3.5
7	0.5	4.5	8	1.4	3.5
9	0.8	2	10	1.8	3
11	1.9	3	12	2	3
13	2.1	3	14	2.2	3
15	2.3	3.5	16	2.7	3.5
17	2.5	3			

2. 실험 결과

2.1 자율주행차 탑승자 데이터셋

<Table 4> fold별 골격 모델 및 퓨전 모델 평가 정확도 비교

fold	골격 모델 평가 정확도 (%)	퓨전 모델 평가 정확도 (%)
1	81.97	90.48
2	80.23	89.75
3	75.05	86.45
4	76.69	88.75
Avg	78.48	88.85

20명의 피험자를 대상으로 한 실험에서, 모델의 학습 정확도를 검증하기 위해 5명씩 그룹화하여 4-fold 교차 검증 방식을 사용하였다. 실험 데이터로는 각 피험자에 대해 150 프레임 분량의 골격 데이터와 150 프레임 분량의 이미지 시퀀스 데이터를 활용하였다. 먼저, 골격 데이터만을 사용해 학습한 결과 평균 78.48%의 정확도를 기록하였다. 반면, 골격 데이터와 이미지 시퀀스 데이터를 결합하여 퓨전 방식으로 학습했을 때, 평균 정확도가 88.85%로 약 10% 향상되는 성과를 확인할 수 있었다. 이는 골격 데이터와 이미지 시퀀스 데이터가 서로 보완적으로 작용하여 서로 다른 조명 환경에서 촬영한 데이터로부터 행동에 대한 정확한 특징 표현을 학습했음을 보여준다.

<Table 5> 이미지 개수별 퓨전 모델 평가 정확도 비교

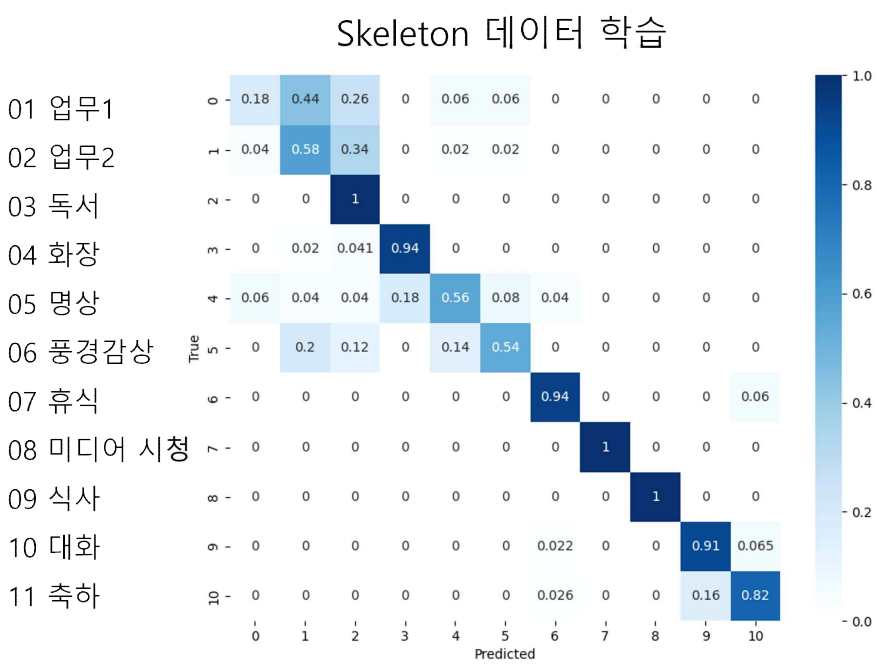
이미지 개수	평가 정확도 (%)
150	90.48
75	88.23
30	86.7
1	76.69

추가 실험으로 이미지 시퀀스 데이터의 분량 변화가 학습 성능에 미치는 영향을 분석하였다. 이미지 데이터의 샘플 개수를 150 프레임에서 75, 30, 1 프레임으로 점차 줄여가며 모델의 정확도를 비교한 결과, 프레임 수가 감소함에 따라 정확도 역시 점진적으로 낮아지는 경향을 보였다. 이를 통해 충분한 분량의 이미지 시퀀스 데이터가 제공될 때 퓨전 모델의 학습 정확도가 더욱 높아진다는 사실을 확인할 수 있었다. 이러한 결과는 골격 데이터와 이미지 시퀀스 데이터의 상호 보완적 특성을 최대한 활용할 수 있도록 데이터의 양과 품질이 학습 성능에 중요한 요소임을 강조한다.

<Table 6> 레이트 퓨전 방식에 따른 퓨전 모델 평가 정확도 비교

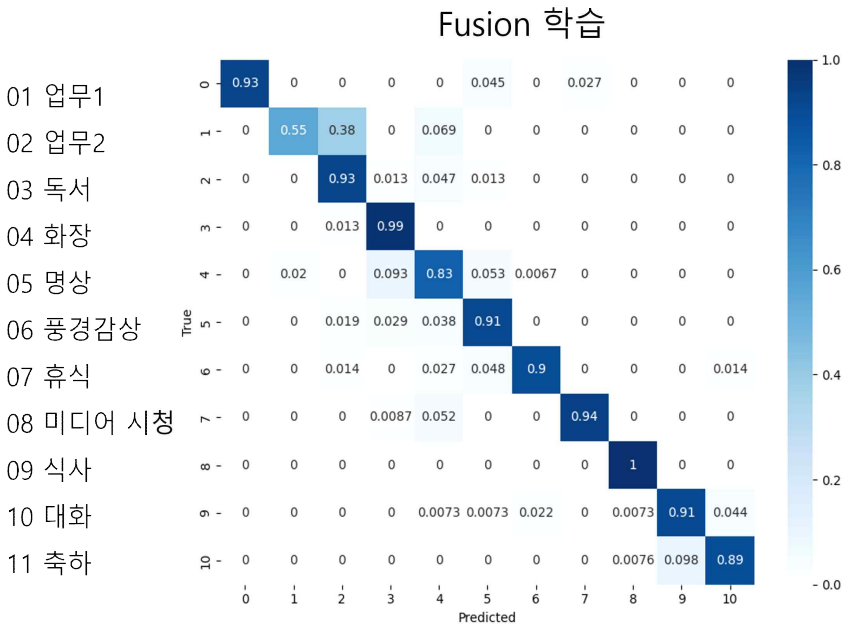
퓨전 방식	평가 정확도 (%)
Add	90.48
Mul	91.23
Max	91.47
Avg	90.23

또한, 가장 좋은 성능을 보였던 1 fold에 대하여 4가지 late fusion 방식에 대한 모델 정확도를 비교해보았다. 레이트 퓨전 방식에 따른 학습 성능에 미치는 영향을 분석하였다. 더하기(Add), 곱하기(Mul), 큰 수 비교(Max), 평균(Avg) 4가지 방식에 대하여 모델의 정확도를 비교한 결과, 큰 수 비교(Max) 퓨전을 사용하였을 때 모델의 평가 정확도가 가장 높았다.



<Figure 29> 골격 데이터 학습에 대한 Class별 정확도 비교

Figure 29는 골격 데이터만을 사용하여 학습한 결과를 나타나며, 대각선 값이 높은 경우 해당 행동 클래스의 예측이 정확함을 의미한다. 독서(클래스 3)와 화장(클래스 4) 등 일부 클래스에서는 높은 인식 정확도를 보였으나, 명상(클래스 5)과 풍경감상(클래스 6)과 같은 행동에서는 혼동이 발생하였다. 이는 골격 데이터만으로는 행동 간의 특징을 충분히 구별하지 못하는 한계가 있음을 시사한다.

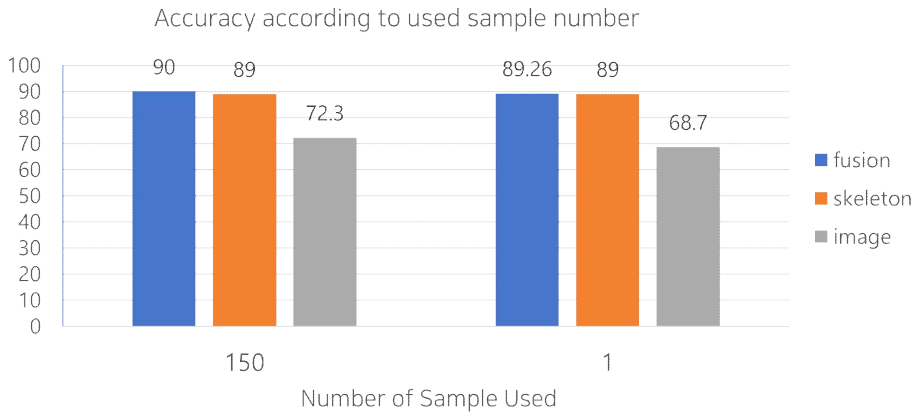


<Figure 30> 이미지-골격 데이터 학습에 대한 Class별 정확도 비교

Figure 30은 골격 데이터와 이미지 시퀀스 데이터를 결합하여 퓨전 모델을 학습한 결과를 보여준다. 골격 데이터만 사용한 경우와 비교하여, 대부분의 클래스에서 대각선 값이 크게 향상되어 인식 정확도가 전반적으로 증가했음을 확인할 수 있다. 특히, 명상(클래스 5), 풍경감상(클래스 6), 축하(클래스 11)와 같은 클래스에서 정확도가 크게 개선되었다. 이는 골격 데이터와 이미지 시퀀스 데이터가 상호 보완적으로 작용하여 행동 간의 차이를 더욱 명확히 학습할 수 있음을 보여준다.

Confusion Matrix 분석을 통해, 골격 데이터만으로 학습한 모델은 일부 클래스에서 인식 한계가 있었으나, 퓨전 모델은 골격 데이터와 이미지 데이터를 결합하여 이러한 한계를 극복하고 전반적인 행동 인식 정확도를 크게 향상시켰다. 이는 두 데이터 소스의 상호 보완적인 정보를 효과적으로 활용함으로써 모델의 성능을 개선할 수 있음을 입증한다.

2.2 NTU RGB+D 데이터셋



<Figure 31> NTU RGB+D 데이터셋의 입력 데이터별 모델 평가 정확도

<Table 7> NTU RGB+D 데이터셋의 퓨전 모델 평가 정확도 비교

이미지 개수	평가 정확도
300	X
150	90.00
1	89.26

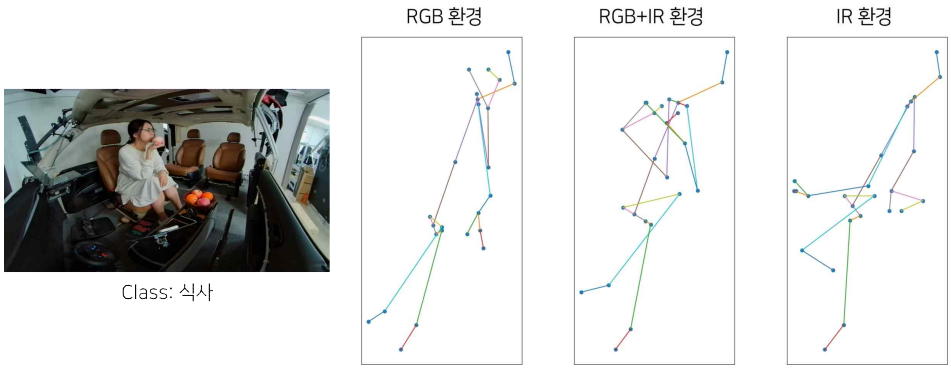
위 자율주행차 탑승자 데이터셋 실험 결과 가장 높은 성능을 보여주었던 큰 수 비교(Max) 퓨전 방법을 사용하여 NTU RGB+D 데이터셋에 대하여 실험을 진행하였다. Figure 31은 이미지 시퀀스 데이터의 프레임 수가 150개일 때와 1개일 때, 퓨전, 골격, 이미지 시퀀스 학습 모델의 성능 차이를 보여준다. 퓨전 모델은 두 경우 모두 가장 높은 정확도를 기록하며, 레이트 퓨전을 통해 프레임 수와 상관없이 안정적인 성능을 제공하는 것으로 나타났다. 골격 학습 모델은 이미지 시퀀스 학습 모델보다 높은 성능을 보였고, 이미지 시퀀스 학습 모델은 다른 두 모델에 비해 상대적으로 낮은 정확도를 보였다. 특히, 프레임 수가 150개일 때 약 70%의 정확도를 기록했지만, 프레임 수가 1개로 줄어들면 정확도가 다소 감소하는 경향이 있었다. 이는 이미지 시퀀스 데이터만 사용할 경우, 프레임 수가 충분하지 않으면 성능이 제한될 수 있음을 시사한다. 전반적으로 퓨전

모델과 골격 학습 모델은 프레임 수 변화에 덜 민감하며, 특히 퓨전 모델은 데이터 퓨전의 강점을 통해 가장 안정적인 성능을 제공하는 것으로 분석된다.

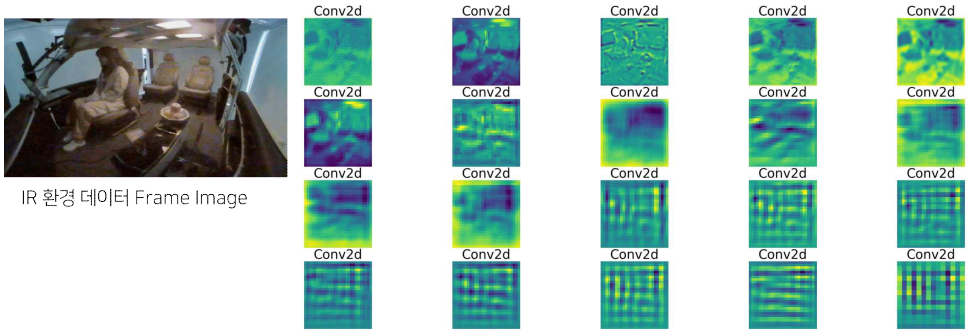
그러나 300 프레임 분량의 이미지 시퀀스 데이터를 입력하면 메모리 초과 문제로 학습에 제약이 발생하였다. 이는 높은 해상도의 이미지 시퀀스 데이터 처리에서 발생할 수 있는 연산 자원의 한계를 보여준다.

결론적으로, 퓨전 모델은 골격 데이터와 이미지 시퀀스 데이터를 결합하여 두 모달리티의 장점을 효과적으로 활용함으로써 가장 높은 성능을 달성하였다. 골격 데이터 단독 사용은 계산 효율성과 성능 측면에서 우수한 결과를 보였으며, 메모리나 연산 자원이 제한적인 환경에서 활용성이 높다. 이미지 시퀀스 데이터는 풍부한 시각적 정보를 제공하지만, 메모리와 계산 효율을 개선하기 위한 추가적인 연구가 필요하다.

3. 데이터 퓨전 기법의 효과 분석



<Figure 32> 조명 환경별 골격 데이터 품질 비교



<Figure 33> IR 환경에서 촬영한 이미지 특징맵 추출 결과

스켈레톤 데이터와 이미지 데이터를 함께 학습한 결과가 더 우수했던 이유는 이미지 데이터가 스켈레톤 데이터의 약점을 보완했기 때문이다.

스켈레톤 데이터는 주변 환경의 조명 조건에 따라 품질이 크게 영향을 받는다. 어두운 조명 환경에서는 스켈레톤 데이터를 정확하게 추출하기 어려워지며, 이로 인해 학습 성능이 저하될 가능성이 높다. 반면, 이미지 데이터를 함께 사용하면 이미지에서 사람의 윤곽이나 형태와 같은 특징을 학습할 수 있어, 조명이 부족한 상황에서도 효과적으로 보완할 수 있다.



<Figure 34> 로우레벨 특징(Low-level feature)이 담긴 특징맵 추출 결과

실험 결과에서 합성곱 신경망 레이어를 통해 생성된 특징맵을 보면, 이미지 데이터를 활용한 학습이 사람의 윤곽을 뚜렷하게 파악하고 추상화하는 데 기여한 것을 확인할 수 있다. 이러한 이유로, 스켈레톤 데이터 단독 학습보다 이미지 데이터를 병합한 학습 방식이 더욱 효과적인 결과를 도출할 수 있었다.

Ⅴ. 결론

본 연구는 인간의 자세를 추정할 때 조명 환경의 민감성을 극복할 수 있는 모델을 만들기 위해, 이미지 시퀀스 데이터와 골격 데이터를 사용하여 학습하였다. 이때 형태가 서로 다른 두 데이터를 동시에 학습하기 위하여 데이터 퓨전 기법을 사용하였고, 레이트 퓨전을 적용하여 이미지 학습을 위한 CNN-LSTM과 ST-GCN을 사용하여 퓨전 모델을 구성하였다.

실험 결과, 골격 데이터만을 사용한 모델은 평균 78.48%의 평가 정확도를 기록했으나, 골격 데이터와 이미지 시퀀스 데이터를 결합한 퓨전 모델은 88.85%로 약 10% 향상된 성과를 보였다. 이는 두 데이터 소스가 상호 보완적으로 작용하여, 더 정확한 특징 표현을 학습하게 해주었음을 의미한다.

또한, 이미지 시퀀스 데이터의 프레임 수가 학습 성능에 미치는 영향을 분석한 결과, 이미지 시퀀스 데이터의 프레임 수가 감소할수록 모델의 평가 정확도가 낮아지는 경향을 보였다. 이로써 충분한 양의 데이터가 모델 성능 향상에 중요한 역할을 한다는 사실을 확인할 수 있었다.

Confusion Matrix 분석 결과, 골격 데이터만을 사용한 모델은 일부 클래스에서 인식 정확도가 낮았으나, 퓨전 모델은 전반적으로 정확도를 크게 향상시켰다. 특히, 명상, 풍경 감상, 축하와 같은 클래스에서 큰 개선을 보였으며, 이는 골격 데이터와 이미지 시퀀스 데이터가 상호 보완적으로 작용하여 행동 간의 차이를 명확히 학습할 수 있게 했음을 보여준다.

또한, 레이트 퓨전 방식에 따른 학습 성능에 미치는 영향을 분석하였다. 더하기(Add), 곱하기(Mul), 큰 수 비교(Max), 평균(Avg) 4가지 방식에 대하여 모델의 정확도를 비교한 결과, 큰 수 비교(Max) 퓨전을 사용하였을 때 모델의 평가 정확도가 가장 높았다.

이 연구는 골격 데이터와 이미지 시퀀스 데이터를 결합한 퓨전 모델이 단일 데이터 소스를 사용하는 경우보다 더 높은 성능을 나타내며, 다양한 상황에서의 행동 인식에 효과적으로 활용될 수 있음을 시사한다. 또한, 향후 연구에서는 다양한 조명 환경이나 카메라 각도에서도 일관된 성능을 유지할 수 있도록 모델을 개선하는 방향으로 나아갈 필요가 있다.

참 고 문 헌

[1] Ce Zheng, et al., “Deep learning-based human pose estimation: A survey,“ ACM Computing Surveys, vol. 56, no. 1, pp. 1-37, 2023.

[2] M. Karim, et al., “Human action recognition systems: A review of the trends and state-of-the-art,“ IEEE Access, pp. 36372-36390, 2024.

[3] L. M. Dang, et al., “Sensor-based and vision-based human activity recognition: A comprehensive survey,“ Pattern Recognition, vol. 108, pp. 107561, 2020.

[4] H. A. Ullah, et al., “Analysis of deep neural networks for human activity recognition in videos—a systematic literature review,“ IEEE Access, vol. 9, pp. 126366-126387, 2021.

[5] S. Gupta, “Deep learning based human activity recognition (HAR) using wearable sensor data,“ International Journal of Information Management Data Insights, vol. 1, no. 2, pp. 100046, 2021.

[6] Y. Liu, et al., “From action to activity: sensor-based activity recognition,“ Neurocomputing, vol. 181, pp. 108-115, 2016.

[7] C. Aviles-Cruz, et al., “Granger-causality: An efficient single user movement recognition using a smartphone accelerometer sensor,“ Pattern Recognition Letters, vol. 125, pp. 576-583, 2019.

[8] M. M. Hassan, et al., “Human activity recognition from body sensor data using deep learning,“ Journal of Medical Systems, vol. 42, pp. 1-8, 2018.

[9] J. Ni, et al., “A survey on multimodal wearable sensor-based human action recognition,“ arXiv preprint, arXiv:2404.15349, 2024.

[10] E. P. Ijjina and K. M. Chalavadi, “Human action recognition in RGB-D videos using motion sequence information and deep learning,“ Pattern Recognition, vol. 72, pp. 504-516, 2017.

[11] T.-H. Tan, et al., “Multi-resident activity recognition in a smart home using RGB activity image and DCNN,“ IEEE Sensors Journal, vol. 18, no. 23, pp. 9718-9727, 2018.

[12] K. Alomar, H. I. Aysel, and X. Cai, “RNNs, CNNs and Transformers in Human Action Recognition: A Survey and A Hybrid Model,“ arXiv preprint, arXiv:2407.06162, 2024.

YEUNGNAM UNIVERSITY 1947 영남대학교

[13] S. Gundu and H. Syed, “Vision-based HAR in UAV videos using histograms and deep learning techniques,“ Sensors, vol. 23, no. 5, pp. 2569, 2023.
[14] A. Sánchez-Caballero, D. Fuentes-Jiménez, and C. Losada-Gutiérrez, “Real-time human action recognition using raw depth video-based recurrent neural networks,“ Multimedia Tools and Applications, vol. 82, no. 11, pp. 16213-16235, 2023.
[15] Y.-F. Song, et al., “Constructing stronger and faster baselines for skeleton-based action recognition,“ IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 45, no. 2, pp. 1474-1488, 2022.
[16] S. Ren, “Faster R-CNN: Towards real-time object detection with region proposal networks,“ arXiv preprint, arXiv:1506.01497, 2015.
[17] J. Redmon, “You only look once: Unified, real-time object detection,“ in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 779-788, 2016.
[18] W. Liu, et al., “SSD: Single shot multibox detector,“ in Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, Springer, pp. 21-37, 2016.
[19] K. He, et al., “Mask R-CNN,“ in Proceedings of the IEEE International Conference on Computer Vision, pp. 2961-2969, 2017.
[20] K. Sun, et al., “Deep high-resolution representation learning for human pose estimation,“ in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 5693-5703, 2019.
[21] Xiao, Bin, Haiping Wu, and Yichen Wei. “Simple baselines for human pose estimation and tracking.“ Proceedings of the European Conference on Computer Vision (ECCV). pp. 466-481, 2018.
[22] Cao, Zhe, et al. “Realtime multi-person 2D pose estimation using part affinity fields.“ Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). pp. 7291-7299, 2017.
[23] Kreiss, Sven, Lorenzo Bertoni, and Alexandre Alahi. “Pifpaf: Composite fields for human pose estimation.“ Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 11977-11986, 2019.
[24] Cheng, Bowen, et al. “HigherHRNet: Scale-aware representation learning for bottom-up human pose estimation.“ Proceedings of the IEEE/CVF

Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5386-5395, 2020.
[25] Rehman, Atiq, and Samir Brahim Belhaouari. "Deep learning for video classification: A review." Authorea Preprints (2021).
[26] Neimark, Daniel, et al. "Video transformer network." Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 3163-3172, 2021.
[27] Girdhar, Rohit, et al. "Video action transformer network." Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 244-253, 2019.
[28] Lan, Zhenzhong, et al. "Deep local video feature for action recognition." Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), pp. 1-7, 2017.
[29] Karpathy, Andrej, et al. "Large-scale video classification with convolutional neural networks." Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1725-1732, 2014.
[30] Mutegeki, Ronald, and Dong Seog Han. "A CNN-LSTM approach to human activity recognition." 2020 International Conference on Artificial Intelligence in Information and Communication (ICAIIC). IEEE, 2020.
[31] Ouyang, Xi, et al. "A 3D-CNN and LSTM based multi-task learning architecture for action recognition." IEEE Access 7 (2019): 40757-40770.
[32] Srivastava, Nitish, Elman Mansimov, and Ruslan Salakhudinov. "Unsupervised learning of video representations using LSTMs." International Conference on Machine Learning (ICML). PMLR, 2015.
[33] Ur Rehman, Atiq, et al. "On the use of deep learning for video classification." Applied Sciences 13.3 (2023): 2007.
[34] Ji, Shuiwang, et al. "3D convolutional neural networks for human action recognition." IEEE Transactions on Pattern Analysis and Machine Intelligence 35.1 (2012): 221-231.
[35] Shen, Junzhong, et al. "Toward an efficient deep pipelined template-based architecture for accelerating the entire 2-D and 3-D CNNs on FPGA." IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems 39.7 (2019): 1442-1455.
[36] Ji, Shuiwang, et al. "3D convolutional neural networks for human action

recognition.“ IEEE Transactions on Pattern Analysis and Machine Intelligence 35.1 (2012): 221-231.

[37] Tran, Du, et al. “Learning spatiotemporal features with 3D convolutional networks.“ Proceedings of the IEEE International Conference on Computer Vision (ICCV), pp. 4489-4497, 2015.

[38] Kopuklu, Okan, et al. “Resource efficient 3D convolutional neural networks.“ Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW). 2019.

[39] Duta, Ionut C., et al. “Boosting VLAD with double assignment using deep features for action recognition in videos.“ 2016 23rd International Conference on Pattern Recognition (ICPR). IEEE, 2016.

[40] Simonyan, Karen, and Andrew Zisserman. “Two-stream convolutional networks for action recognition in videos.“ Advances in Neural Information Processing Systems 27 (2014).

[41] Feichtenhofer, Christoph, Axel Pinz, and Andrew Zisserman. “Convolutional two-stream network fusion for video action recognition.“ Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1933-1941, 2016.

[42] Kipf, Thomas N., and Max Welling. “Semi-supervised classification with graph convolutional networks.“ arXiv preprint arXiv:1609.02907 (2016).

[43] Scarselli, Franco, et al. “The graph neural network model.“ IEEE Transactions on Neural Networks 20.1 (2008): 61-80.

[44] Krizhevsky, Alex, Ilya Sutskever, and Geoffrey E. Hinton. “ImageNet classification with deep convolutional neural networks.“ Advances in Neural Information Processing Systems 25 (2012): 84-90

[45] Meng, Tong, et al. “A survey on machine learning for data fusion.“ Information Fusion 57 (2020): 115-129.

[46] Singh, Apoorv. “Vision-radar fusion for robotics BEV detections: A survey.“ 2023 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2023.

[47] Chen, Xiaozhi, et al. “Multi-view 3D object detection network for autonomous driving.“ Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1907-1915, 2017.

[48] Ku, Jason, et al. “Joint 3D proposal generation and object detection from view aggregation.“ 2018 IEEE/RSJ International Conference on Intelligent

Robots and Systems (IROS). IEEE, 2018.
[49] Liang, Ming, et al. “Deep continuous fusion for multi-sensor 3D object detection.“ Proceedings of the European Conference on Computer Vision (ECCV), pp. 641-656, 2018.
[50] Bai, Xuyang, et al. “TransFusion: Robust LiDAR-camera fusion for 3D object detection with transformers.“ Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1090-1099, 2022.
[51] Milch, Stefan, and Marc Behrens. “Pedestrian detection with radar and computer vision.“ Proceedings of PAL 2001—Progress in Automobile Lighting. 2001.
[52] Garcia, Fernando, et al. “Data fusion for overtaking vehicle detection based on radar and optical flow.“ 2012 IEEE Intelligent Vehicles Symposium. IEEE, 2012.
[53] Rastgoo, Mohammad Naim, et al. “Automatic driver stress level classification using multimodal deep learning.“ Expert Systems with Applications 138 (2019): 112793.
[54] Ortega, Juan DS, Patrick Cardinal, and Alessandro L. Koerich. “Emotion recognition using fusion of audio and video features.“ 2019 IEEE International Conference on Systems, Man, and Cybernetics (SMC). IEEE, 2019.
[55] Lim, Teck-Yian, et al. “Radar and camera early fusion for vehicle detection in advanced driver assistance systems.“ Machine Learning for Autonomous Driving Workshop at the 33rd Conference on Neural Information Processing Systems. Vol. 2, 2019.
[56] Gautam, Shivam, et al. “SDVTracker: Real-time multi-sensor association and tracking for self-driving vehicles.“ Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 3012-3021, 2021.
[57] Krieg, Mark L. “Joint multi-sensor kinematic and attribute tracking using Bayesian belief networks.“ Sixth International Conference of Information Fusion (FUSION). IEEE, 2003.
[58] Kim, Kyeong-Eun, et al. “Sensor fusion for vehicle tracking with camera and radar sensor.“ 2017 17th International Conference on Control, Automation and Systems (ICCAS). IEEE, 2017.

[59] Eitel, Andreas, et al. “Multimodal deep learning for robust RGB-D object recognition.“ 2015 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2015.
[60] Pandeya, Yagya Raj, and Joonwhoan Lee. “Deep learning-based late fusion of multimodal information for emotion classification of music video.“ Multimedia Tools and Applications 80.2 (2021): 2887-2905.
[61] Graves, Alex. “Long short-term memory.“ Supervised Sequence Labelling with Recurrent Neural Networks. Springer, 2012. 37-45.
[62] Yan, Sijie, Yuanjun Xiong, and Dahua Lin. “Spatial temporal graph convolutional networks for skeleton-based action recognition.“ Proceedings of the AAAI Conference on Artificial Intelligence (AAAI). Vol. 32, 2018.
[63] Akilan, T., et al. “A late fusion approach for harnessing multi-CNN model high-level features.“ 2017 IEEE International Conference on Systems, Man, and Cybernetics (SMC). IEEE, 2017.
[64] Shi, Yude, and Xiao Ke. “Improved quality aware network using quality and max pooling based late feature fusion for video-based person re-identification.“ 2019 IEEE 7th International Conference on Computer Science and Network Technology (ICCSNT). IEEE, 2019.
[65] Shahroudy, Amir, et al. “NTU RGB+D: A large-scale dataset for 3D human activity analysis.“ Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016.
[66] Liu, Jun, et al. “NTU RGB+D 120: A large-scale benchmark for 3D human activity understanding.“ IEEE Transactions on Pattern Analysis and Machine Intelligence 42.10 (2019): 2684-2701.

M.S. Thesis

Human Action Classification Using Fusion Technique for Image and Skeleton Data

Kim Nahyeon

Department of Electronics Engineering

Graduate School

Yeungnam University

(Supervised by professor Lee, Chan-Su)

Abstract

Modern advancements in computer vision and artificial intelligence have achieved remarkable progress in human action recognition and motion analysis. These advancements have primarily been based on image and video, and recently, research utilizing skeleton data has also gained attention. Images provide visual information, while skeleton data quantifies human motion, enabling richer insights.

This paper proposes the scheme to effectively learn and classify human actions by combining image and skeleton data. ST-GCN is used to extract features from skeleton data, and CNN-LSTM is used to extract features from image. The two sets of features, obtained from each model, are then fused to generate the final result. We compared the classification performance of the

proposed image-skeleton fusion model with that of models trained on single data types.